

Experimento y decisión

Diseño

Una consulta, porque el equipo es de un integrante, corrida en tres tratamientos (protocolo-experimento-v1.md): «¿Qué estudios han medido cuánto se sobreestima el desempeño de los clasificadores de lesiones de piel cuando los datos se parten por imagen o por lesión en vez de por paciente? Dame 5 referencias, cada una con la afirmación concreta que sostiene y su DOI.»

A, el control, es un chat sin fuentes: llama3.1:8b en Ollama, en local, sin conexión y sin instrucción de sistema. **B** es Consensus, en su modo por defecto. **C** es NotebookLM, con los 22 archivos de corpus-c.md.

De cada respuesta se tomaron las primeras 5 referencias. Cada una se abrió y se clasificó como no existe, existe pero no dice eso, o utilizable. Se clasificó dos veces, sobre hojas mezcladas y sin la columna de tratamiento, y las discrepancias se leyeron una tercera vez. El análisis lo hizo analizar.py.

Conteos y proporciones

Clasificación final (resultados.json). La proporción es la de referencias utilizables, con intervalo de Wilson al 95 %:

Tratamiento	Entregadas	No existe	No dice eso	Utilizable	Proporción [IC 95 %]	Se abstuvo
A · chat sin fuentes	5	5	0	0	0,00 [0,0000; 0,4345]	sí
B · Consensus	5	0	2	3	0,60 [0,2307; 0,8824]	no
C · NotebookLM	5	0	3	2	0,40 [0,1176; 0,7693]	no

Con 5 referencias por tratamiento los intervalos son anchos, y los de B y C se solapan. Las referencias de un tratamiento salen de una sola respuesta y no son independientes, así que no se hace ninguna prueba entre tratamientos. Lo claro es que las 5 referencias del control no existen.

Consistencia de la clasificación

Las dos pasadas no coinciden en **1 de 15 referencias**. El kappa de Cohen es 0,90, un dato secundario y sin inferencia, porque con 15 referencias es inestable.

La discrepancia es la de **Jamaludin y Kim (2026)**, de B: «existe pero no dice eso» en la pasada 1 y «utilizable» en la 2. Las cifras que se le atribuyen, 94,57 % y 78,41 %, están en el resumen. El texto completo, en cambio, atribuye unos 11 puntos a la fuga y de 5 a 7 a la varianza de una sola semilla. La tercera lectura la dejó en «existe pero no dice eso» (tercera-lectura.csv).

Desviaciones declaradas

Están en desviaciones.md. (1) La primera corrida de A, en claude.ai, se descartó porque tenía la búsqueda web activa. (2) A pasó a un modelo local: el control es más estricto, pero el modelo es más pequeño y de otra familia que Claude. (3) Las reglas de extracción se fijaron antes de clasificar. (4) La hoja de la pasada 1 se regeneró, porque el formato delataba el tratamiento. (5) Las pasadas las hizo Claude. (6) La pasada 2 no esperó 48 horas. (7) La tercera lectura no fue ciega. (8) Revisé las dos pasadas, el 3 y el 5 de octubre, sobre las hojas ya clasificadas, sin cambiar ninguna hoja. (9) En la auditoría manual de 5 referencias, discrepé de las dos pasadas en Kapoor y Narayanan (2023), que puse en «no dice eso»; el hallazgo no se aplicó.

Decisión

Con los seis criterios del enunciado. La tabla completa, con qué se midió y qué se juzgó sin medir, está en tabla-decision.md. El banco de 20 preguntas de respuesta conocida (banco-resultados.md) completa el experimento.

Herramienta	Dato que decide	Decisión
NotebookLM	Banco: 20 de 20 [0,8389; 1,0000]; se abstuvo en las 3 preguntas fuera del corpus	Elegida para anclaje , con el protocolo v2 y abriendo el pasaje citado
Consensus	3 de 5 utilizables; un DOI erróneo	Solo para buscar referencias nuevas , abriéndolas siempre
Chat sin fuentes	0 de 5, las 5 inexistentes; 0 de 17 en el banco	Descartada
Proyecto de Claude con archivos	Sin medir: la cuenta no deja apagar la búsqueda web	Descartada
Vía propia (Ollama, embeddings y Chroma)	Sin medir: corpus público, construcción costosa	Descartada
Claude Code sobre referencias/	Comprobaciones con guion	Para verificar, no para consultar

La biblioteca y la exportación a APA 7 son de Zotero para todas.