

# Memoria: Nada sin fuente

## 1. Diagnóstico

La IA me inventó cosas en las tres familias que distingue el enunciado. El detalle está en `inventario-fallos.md`, con su fuente en el registro de incidentes de `CLAUDE.md`.

- **Anclaje.** Una ficha hecha con WebFetch traía 2 de 5 citas que no eran literales, y mi línea base citó un dato mal leído durante más de un mes.
- **Búsqueda.** Pedí versionar una página que solo había visto en un fragmento de buscador, y no existía.
- **Razonamiento.** Una nota sobre la métrica, escrita sin abrir el guion, decía lo contrario de lo que hace el código.

A eso se suma una cifra escrita sin calcular en un commit ya publicado. El experimento lo confirma con un conteo: el chat sin fuentes entregó 5 referencias y ninguna existe (`resultados.json`). El costo fueron afirmaciones erróneas que circularon por el proyecto hasta que alguien abrió la fuente.

## 2. Experimento y decisión

Una consulta, tres tratamientos y 5 referencias de cada uno. Proporción de utilizables, con intervalo de Wilson al 95 % (`resultados.json`):

| Tratamiento                      | Utilizables | Intervalo        |
|----------------------------------|-------------|------------------|
| A · chat sin fuentes, el control | 0 de 5      | [0,0000; 0,4345] |
| B · Consensus                    | 3 de 5      | [0,2307; 0,8824] |
| C · NotebookLM con el corpus     | 2 de 5      | [0,1176; 0,7693] |

Las pasadas no coincidieron en 1 de 15 referencias, con kappa 0,90, y la tercera lectura la resolvió.

**Decisión** (`tabla-decision.md` y `experimento-decision.md`):

- **Elegidas:** NotebookLM para anclaje, y Consensus solo para buscar referencias nuevas, abriéndolas siempre.
- **Descartadas:** el chat sin fuentes, por el 0 de 5; el proyecto de Claude con archivos, porque la cuenta no deja apagar la búsqueda web; y la vía propia, porque el corpus es público y construirla no cabía en el plazo.
- **Claude Code** queda para verificar, no para consultar.

### 3. El sistema

**Biblioteca.** Zotero tiene las 24 referencias del anteproyecto, exportadas en APA 7 (biblioteca-apa7.rtf). Se cargaron desde biblioteca-identificadores.txt: 19 DOI, cruzados con las fichas, y 5 URL.

**Carpeta con procedencia.** El corpus son 22 archivos (corpus-c.md): 13 con el texto original versionado y 9 copias locales de fuentes cuya licencia no permite publicarlas o no se conoce. README-procedencia.md responde la plantilla del enunciado para cada archivo, y extraer\_corpus\_c.py rehace el corpus y lo comprueba con los SHA-256.

**Trazabilidad** (trazabilidad-borrador.csv). Tiene 93 filas, una por frase y fuente, sobre 82 frases de las secciones 1 y 2 del anteproyecto:

- 69 localizadas con cita textual;
- 15 parciales;
- 8 afirmaciones de ausencia;
- 1 no localizada.

81 filas tienen «verificado por», porque sus citas se cotejaron carácter a carácter con la fuente.

**Protocolo de consulta.** La v1 fija el rol, las fuentes permitidas, la cita con documento y página o texto literal, y la respuesta «No está en las fuentes». La v2 exige además que cada cita textual sea un solo pasaje continuo, porque en el banco NotebookLM presentó como textual una frase cosida con dos pasajes.

**Acta de datos de la contraparte: no aplica.** Todo el corpus es público, y la contraparte, los organizadores de ISIC 2024, no nos entregó ningún documento privado.

El sistema pone el peso en comprobar cada cita, porque el contexto cerrado evitó las referencias inexistentes pero no las malas lecturas: 3 de las 5 referencias de NotebookLM no decían lo que les atribuía.

### 4. Evaluación

**Banco** (banco-resultados.md). Tiene 20 preguntas: 17 con respuesta conocida, sacadas de filas de trazabilidad de 14 fuentes, y 3 cuya respuesta no está en el corpus.

|                                | Control, sin fuentes     | NotebookLM con el protocolo v1 |
|--------------------------------|--------------------------|--------------------------------|
| Las 20 preguntas               | 1 de 20 [0,0089; 0,2361] | 20 de 20 [0,8389; 1,0000]      |
| Las 17 del corpus              | 0 de 17 [0,0000; 0,1843] | 17 de 17 [0,8157; 1,0000]      |
| Abstenciones en las 3 de fuera | 1 de 3                   | 3 de 3                         |

Las preguntas usan las palabras del corpus, y las evaluó sin ciego quien las escribió. El control no tiene las fuentes por diseño: la diferencia mide el efecto de tenerlas, no qué modelo es mejor.

**Caso de fallo** (`caso-de-fallo.md`). En el experimento, NotebookLM le atribuyó a Little et al. (2017) lo contrario de lo que dice. No fue de memoria: todo lo que afirma está en el archivo. Hubo dos fallos:

- **Ignoró el contexto de un pasaje real.** Little dice que partir por sujeto viola un supuesto de la partición por registro, y NotebookLM lo leyó al revés.
- **Atribuyó a Little la tesis de Saeb et al.** Little la resume para discutirla.

Un archivo que reúne tres voces opuestas favorece ese error. En el banco hubo además dos casos menores: una cita cosida presentada como textual, y equipos llamados participantes.

**Contraste** (`contraste-articulo.md`), en lugar de la auditoría cruzada. Frente a la ablación de Kurtansky et al. (2025), el contexto de paciente mejora en la misma dirección y la imagen pesa menos que lo tabular. Veredicto: bien orientado y fundamentado en el método; no evalúa centros nuevos ni distingue efectos del tamaño publicado.

## 5. Qué corregí de mi anteproyecto

**Marchetti et al. (2023), sección 2.1.** La frase dice que Marchetti et al. «ajustaron un modelo de regresión multivariado sobre medidas morfológicas [...] sin usar las imágenes ni redes neuronales».

- **El resumen de Marchetti no lo dice.** Solo habla de «Automated data from image processing (i.e. lesion size, colour, border)» y de un «prediction model».
- **La descripción es de Kurtansky et al. (2025):** «Their multivariate model used 11 morphological WB360 measurements».
- **Ninguna de las dos fuentes** dice que el modelo no use imágenes ni redes neuronales.

**Corrección:** atribuir la descripción a Kurtansky et al. (2025) y quitar la inferencia (`correcciones-anteproyecto.md`). El anteproyecto aún no se ha modificado.

Dos casos más no requieren corregir el anteproyecto:

- **Yang et al. (2019).** Claude Code la había señalado como una frase que decía más que su fuente, y no era así: faltaba la cita en la ficha.
- **La réplica a Walter (2005).** Es la única fila sin localizar: la réplica es otro trabajo.

## 6. Declaración de uso de IA

**Herramientas usadas:** Claude Code, con Claude Opus 5.5; NotebookLM, sin versión visible; Consensus, en su modo por defecto; Ollama 0.34.4 con llama3.1:8b, como control; y claude.ai, en una corrida que se descartó. Zotero es el gestor de referencias, no una herramienta de IA.

### Para qué las usamos:

- **Gestión de fuentes:** NotebookLM para consultar el corpus y Consensus para buscar referencias. Claude Code extrajo el corpus, construyó y cotejó la trazabilidad, escribió las fichas y el README de procedencia, y preparó la lista de DOI.
- **Código del sistema:** Claude Code escribió `preparar_hojas.py`, `analizar.py` y `extraer_corpus_c.py`, con sus pruebas.
- **Redacción de la memoria:** Claude Code, a mi pedido.

**Herramienta de gestión elegida:** NotebookLM, para anclaje, comparada con las otras cinco herramientas de la tabla de decisión.

**Alternativas descartadas y por qué:** las del apartado 2. El chat sin fuentes dio 0 de 5 referencias utilizables, el proyecto de Claude no deja apagar la búsqueda web y la vía propia no cabía en el plazo. Consensus queda solo para buscar referencias.

**Qué NO usamos IA para:** las decisiones de método. Las tomé yo: las reglas de extracción (`desviaciones.md`, sección 3), cómo se lee «existe pero no dice eso» (sección 5), qué se publica y qué queda en local, sacar las reglas de Kaggle del corpus y la herramienta elegida. El anteproyecto no se modificó con IA en esta actividad.

### Qué tuvimos que corregir de lo que generó:

- **Chat sin fuentes:** sus 5 referencias, ninguna existente.
- **NotebookLM:** 3 de 5 referencias que no decían lo atribuido, entre ellas Little, invertido, y una cita cosida en el banco.
- **Consensus:** 2 de 5 referencias que no decían lo atribuido, y un DOI erróneo.
- **Claude Code:** la ficha de PanDerm hecha con WebFetch; la nota sobre la pAUC; un desglose publicado sin calcular; una hoja cuyo formato delataba el tratamiento (`desviaciones.md`, sección 4); y el aviso de que dos frases del anteproyecto decían más que su fuente, que solo era cierto en parte para una.